

東南大學成賢學院

毕业设计(论文)开题报告

题目 巡检无人机图像中对输电线路绝缘子
缺陷异常检测

姓 名 _____ 周宙 _____

学 号 _____ 240321514 _____

所属学院 _____ 机械与电气工程学院 _____

专 业 _____ 电气工程及其自动化 _____

指导教师 _____ 刘同礼 _____

一、课题背景与意义（300 字左右）

随着电力系统的不断扩大和复杂化，输电线路的安全运行变得越来越重要。传统的人工巡检方法存在效率低、危险性高等问题。近年来，无人机巡检技术的应用为解决这些问题提供了新的思路。然而，无人机采集的大量图像数据给后续的分析工作带来了巨大挑战。特别是对于输电线路上的绝缘子，其缺陷检测直接关系到电力系统的安全稳定运行。

本课题旨在研究基于深度学习的无人机巡检图像中绝缘子缺陷异常检测方法。该研究具有重要意义：首先，它可以提高输电线路巡检的效率和准确性，降低人工成本和安全风险；其次，通过自动化检测技术，可以及时发现潜在的设备故障，提高电网运行的可靠性；最后，该研究将推动人工智能技术在电力系统中的应用，为智能电网的发展提供技术支持。此外，本研究的方法和思路也可能为其他工业领域的视觉检测任务提供借鉴。

二、课题拟解决的关键问题及难点（300 左右字）

本课题主要聚焦于解决无人机巡检图像中绝缘子缺陷的自动检测问题。关键问题包括如何有效处理大量复杂背景下的图像数据，如何精确检测各类绝缘子缺陷。研究难点主要体现在以下几个方面：首先，无人机采集的图像往往存在光照不均、角度多变、分辨率不一等问题，这增加了图像预处理和特征提取的难度；再者，绝缘子缺陷类型多样，如裂纹、缺损、污染等，且部分缺陷表现微弱，难以识别；最后，由于实际环境中正常样本远多于异常样本，如何在数据不平衡的情况下提高模型的泛化能力和鲁棒性也是一个重要难点。此外，如何设计一个既能保证检测精度又能满足实时性要求的算法框架，也是本研究需要解决的关键问题。

三、文献综述（1200 字左右）

视觉异常检测（Visual anomaly detection）是一个快速发展的研究领域,应用广泛,包括医疗成像、自动驾驶和工业检测等。这些应用场景通常具有独特的特性,例如监控数据以图像序列形式存在,而医疗成像数据则涉及多种模态类型。本研究专注于检测巡检无人机图像中对输电线路绝缘子缺陷,使用 InsPLAD(Inspection Power Line Anomaly Detection)无人机巡检电路线路设备数据集[1]。InsPLAD 数据集包含 17 个类别的输电线路资产,其中 5 个类别涉及不同的故障条件,如锈蚀、缺失部件和被鸟巢覆盖等。该数据集不仅提供了物体检测的标注,还包含了故障分类的标签,使其成为评估输电线路异常检测算法的理想基准。数据集中的图像来自实际的无人机巡检场景,包含了各种复杂的背景和光照条件,增加了检测和分类任务的难度。此外,InsPLAD 数据集还提供了数据增强的方法,可以将训练数据扩增 10 倍,有助于提高模型的泛化能力。这个数据集的引入为输电线路异常检测研究提供了宝贵的资源,使得研究人员可以更好地开发和评估适用于实际巡检场景的算法。

深度学习的缺陷检测任务中,通常分为两大类检测任务目标,图像级别(Image-level Anomaly Detection)和像素级别(Pixel-level Anomaly Detection),图像级别的任务是在未见过的类别的图像判别异常,像素级别的则是专门用于定位异常情况。它们旨在精确分割图像中的异常区域,这比二进制分类更加复杂。但在工业中需要确保的是没有异常,比如加工零件必须是完美的,因此像素级别的缺陷检测任务更广泛运用,常被视为一个一类学习问题。

图像级异常检测大致可分为基于重建的、基于分布的和基于分类的。

第一类方法通过重建训练图像来捕捉正常数据流形。异常图像在推理过程中很可能具有较高的重建误差,因为它来自不同的分布。这些方法的优秀在于深度模型出色的泛化能力,生成模型如自编码器(Autoencoder)和生成对抗网络(GAN)已被广泛用于异常检测,包括变分自编码器

[2],鲁棒自编码器[3],条件生成对抗网络[4]和双向生成对抗网络[5],可能导致异常图像也能被准确重建。基于自编码器的方法依赖于对正常图像的准确重建和对异常图像的不准确重建[6],[7],[8],[9],从而可以通过比较重建结果和输入图像来检测异常。但是,正常图像重建质量不佳(如产生模糊结果)引发的误报是这类方法的常见缺陷。

基于分布的方法可以对正常图像的概率分布进行建模。概率密度值低于阈值的图像将被判定为异常。最近的算法,如异常检测 GAN (ADGAN) [10] 和深度自编码高斯混合模型 (DAGMM) [11],学习一个深度投影,将高维图像映射到低维潜在空间。但这类方法存在较高的样本复杂度,且需要大量训练数据支持。

基于分类的方法在过去十年里一直主导着异常检测领域。一种有效的方法是将深度生成模型[9]或将预训练网络[12],[13]提取的深层特征输入独立的浅层分类模型,如一类支持向量机(OC-SVM) [14]。另一种研究方向是基于自监督学习。Geom[15]通过对正常图像应用多种几何变换来创建数据集,并训练一个多类神经网络来识别这些变换。在测试阶段,预期异常样本在识别这些变换时会表现

出较低的置信度。

像素级异常检测研究通常探索如何将图像分类任务上预训练网络的优势应用于异常检测。Napoleitano 等人[16]利用预训练的 ResNet-18[17]将裁剪的训练图像块嵌入到特征空间,通过主成分分析降低特征向量的维度,然后使用 K-means 聚类对其分布进行建模。这种方法需要大量重叠图像块才能生成空间异常热力图,这会导致粗糙的结果,并可能成为性能瓶颈。为了避免裁剪图像块并加快特征提取,Sabokrou 等人[18]从预训练的完全卷积网络 (FCN) 的早期特征图构建描述符,并采用单模高斯分布来拟合无异常图像的特征向量。然而,当问题复杂度提升时,单峰高斯分布难以准确表征特征分布。最近,一种带有引导注意力的卷积对抗性变分自编码器 (CAVGA) [19]将 Grad-CAM[20]纳入变分自编码器,并采用注意力扩展损失,鼓励深度模型关注图像中所有正常区域。

四、方案（设计方案、研制方案、研究方案）设计及论证（不少于 900 字）

为了有效地检测巡检无人机图像中输电线路绝缘子的缺陷异常，本研究提出了一种强化后的学生-教师框架的混合异常检测方法，以下简称 MSTAD (Multi-scale Student-Teacher Anomaly Detection)。该方法在保留 STFPM (Student-Teacher Feature Pyramid Matching) [21] 多层级特征匹配优势的基础上，引入了 EfficientAD[22] 的硬样本挖掘策略，结合了 L2 正则化处理特征，并可选地加入 ImageNet[23] 惩罚项。通过这一系列改进，我们旨在提升模型对异常检测的精度和鲁棒性，特别是在训练数据不平衡、异常样本稀少的情况下，增强模型的泛化能力。

4.1 方法概述

传统的异常检测方法如 STFPM 利用学生-教师网络架构，其中教师网络预先在大规模数据集（如 ImageNet）上训练，学生网络则在目标任务的数据集上学习，通过模仿教师网络的特征表示来捕获正常数据的分布。然而，STFPM 存在对小尺度异常敏感度不高、对复杂异常检测能力有限等问题。

为了解决上述问题，我们引入了 EfficientAD 的硬样本挖掘策略，使模型在训练过程中更加关注难以学习的样本，从而提升对异常的检测能力。同时，使用 L2 正则化处理特征，消除特征尺度差异，稳定训练过程。此外，可选地添加 ImageNet 惩罚项，防止学生网络在非目标域数据上的过拟合，提高模型的泛化性能。

4.2 网络结构设计

我们的模型由预训练的教师网络 \mathcal{T} 和需训练的学生网络 \mathcal{S} 组成。教师网络的参数在训练过程中保持不变，专注于提取稳定的特征表示。学生网络结构与教师网络相同，但参数随机初始化，需通过训练来模拟教师网络的特征输出。

为了获取多尺度的特征表示，我们选择了网络的多个层级 L ，如浅层、中层和深层特征，构建特征金字塔。这些层级的特征能够捕捉到从低级边缘、纹理到高级语义的信息，有助于全面检测异常。

对于输入图像 I ，教师网络和学生网络在第 l 层分别提取特征表示：

$$F_T^l(I) = \mathcal{T}^l(I), \quad F_S^l(I) = \mathcal{S}^l(I),$$

其中， $F_T^l(I) \in R^{C_l \times H_l \times W_l}$ ， $F_S^l(I) \in R^{C_l \times H_l \times W_l}$ ， C_l 、 H_l 、 W_l 分别为第 l 层特征的通道数、高度和宽度。

4.3 特征 L2 正则化

为消除不同特征尺度的影响，我们对教师和学生网络的特征进行 L2 正则化处理，即对每个位置的特征向量进行归一化：

$$\widehat{F}_T^l(I)_{ij} = \frac{F_T^l(I)_{ij}}{\|F_T^l(I)_{ij}\|_2}, \quad \widehat{F}_S^l(I)_{ij} = \frac{F_S^l(I)_{ij}}{\|F_S^l(I)_{ij}\|_2},$$

其中， F_{ij} 表示特征图在位置 (i, j) 的特征向量， $\|\cdot\|_2$ 表示 L2 范数。

4.4 损失函数设计

为了训练学生网络有效地模拟教师网络的特征表示，我们设计了包含硬样本挖掘策略的多层级损失函数。

4.4.1 基本特征匹配损失

首先，定义第 l 层在位置 (i,j) 的基本特征匹配损失为：

$$l^l(I)_{ij} = \frac{1}{2} |\widehat{F}_T^l(I)_{ij} - \widehat{F}_S^l(I)_{ij}|_2^2.$$

该损失衡量了学生网络与教师网络在特征空间的差异。

4.4.2 硬样本挖掘策略

为了让模型更关注难以学习的样本，引入硬样本挖掘策略。具体而言，在每个批次训练中，对于第 l 层的损失矩阵 $l^l(I)$ ，计算其元素的 p_{hard} 分位数 d_{hard} ，即：

$$d_{\text{hard}} = \text{Quantile}(l^l(I), p_{\text{hard}}),$$

其中， $p_{\text{hard}} \in [0,1]$ ，表示选择损失较大的前百分比。例如， $p_{\text{hard}} = 0.999$ 表示选择损失最大的 0.1% 的样本。然后，仅对满足 $l^l(I)_{ij} \geq d_{\text{hard}}$ 的位置计算损失，形成硬样本集合 \mathcal{H}^ℓ 。

第 l 层的硬样本损失为：

$$l_{\text{hard}}^l(I) = \frac{1}{|\mathcal{H}^\ell|} \sum_{(i,j) \in \mathcal{H}^\ell} l^l(I)_{ij}.$$

4.4.3 ImageNet 惩罚项（可选）

为防止学生网络在非目标域图像上的过拟合，增强模型的泛化能力，我们引入了 ImageNet 惩罚项。具体地，对从 ImageNet 数据集随机采样的图像 P ，计算学生网络在其上的输出，并对其施加正则化损失：

$$l_{\text{penalty}} = \frac{1}{N_p} \sum_P |\mathcal{S}(P)|_2^2,$$

其中， $\mathcal{S}(P)$ 表示学生网络对图像 P 的输出特征， N_p 为采样的 ImageNet 图像数量。

4.4.4 总损失函数

综合上述，各层级的损失按照权重 α_l 进行加权求和，总的训练损失函数为：

$$l_{\text{total}} = \sum_{l=1}^L \alpha_l l_{\text{hard}}^l(I) + \lambda l_{\text{penalty}},$$

其中， λ 为惩罚项的权重超参数，控制 ImageNet 惩罚项对总损失的影响。一般情况下， α_l 可设为 1，使各层级损失均等贡献。

4.5 方法创新与方案论证

- 1. 保留 STFPM 的多层级特征匹配：利用多层级特征匹配，充分捕捉图像的低级纹理、高级语义等多尺度信息，提升了模型对不同尺度和类型异常的检测能力。
- 2. 引入 EfficientAD 的硬样本挖掘策略：通过专注于损失较大的样本，即模型难以训练的“硬样本”，提高了学生网络对困难样本的学习效果，增强了模型对异常的敏感度。
- 3. 使用 L2 正则化处理特征：对特征向量进行归一化，消除了特征尺度差异的影响，避免了数值不稳定，提高了训练的稳定性 and 模型的鲁棒性。
- 4. 加入 ImageNet 惩罚项（可选）：在学生网络的训练中加入对非目标域图像的惩罚，防止其在不相关数据上的过拟合，增强了模型在实际应用中的泛化能力。

五、工作计划（不少于 300 字）

数据准备与预处理阶段：

先 InsPLAD 数据集中提取绝缘子相关图像，进行详细的探索性数据分析（EDA）。这包括分析图像分辨率、光照条件、角度分布等特征，以及绝缘子缺陷类型的统计。根据分析结果，设计并实现一系列图像预处理步骤，如裁剪、缩放、归一化、数据增强等，以适应后续深度学习模型的输入需求。同时，将数据集划分为训练集、验证集和测试集，确保数据分布的一致性和代表性。

模型构建与训练阶段：

基于预处理后的数据，首先构建和训练一个基于 ResNet 的微调网络作为基线模型。随后，设计并实现改进的学生-教师框架（MSTAD），包括教师网络的预训练、学生网络的结构设计、多尺度特征匹配机制的实现等。重点关注硬样本挖掘策略的整合，以及 L2 正则化和可选的 ImageNet 惩罚项的实现。在训练过程中，密切监控模型性能，及时调整超参数，优化训练策略。

Reference:

[1] A. L. B. Vieira E Silva *et al.*, ‘InsPLAD: A Dataset and Benchmark for Power Line Asset Inspection in UAV Images’, *Int. J. Remote Sens.*, vol. 44, no. 23, pp. 7294–7320, Dec. 2023, doi: 10.1080/01431161.2023.2283900.

[2] J. An and S. Cho, ‘Variational autoencoder based anomaly detection using reconstruction probability’, *Spec. Lect. IE*, vol. 2, no. 1, pp. 1–18, 2015.

[3] C. Zhou and R. C. Paffenroth, ‘Anomaly Detection with Robust Deep Autoencoders’, in *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, Halifax NS Canada: ACM, Aug. 2017, pp. 665–674. doi: 10.1145/3097983.3098052.

[4] S. Akcay, A. Atapour-Abarghouei, and T. P. Breckon, ‘GANomaly: Semi-supervised Anomaly Detection via Adversarial Training’, in *Computer Vision – ACCV 2018*, vol. 11363, C. V. Jawahar, H. Li, G. Mori, and K. Schindler, Eds., in *Lecture Notes in Computer Science*, vol. 11363. , Cham: Springer International Publishing, 2019, pp. 622–637. doi: 10.1007/978-3-030-20893-6_39.

- [5] H. Zenati, M. Romain, C.-S. Foo, B. Lecouat, and V. Chandrasekhar, 'Adversarially Learned Anomaly Detection', in *2018 IEEE International Conference on Data Mining (ICDM)*, Nov. 2018, pp. 727–736. doi: 10.1109/ICDM.2018.00088.
- [6] P. Bergmann, K. Batzner, M. Fauser, D. Sattlegger, and C. Steger, 'Beyond Dents and Scratches: Logical Constraints in Unsupervised Anomaly Detection and Localization', *Int. J. Comput. Vis.*, vol. 130, no. 4, pp. 947–969, Apr. 2022, doi: 10.1007/s11263-022-01578-9.
- [7] P. Bergmann, S. Löwe, M. Fauser, D. Sattlegger, and C. Steger, 'Improving Unsupervised Defect Segmentation by Applying Structural Similarity to Autoencoders', in *Proceedings of the 14th International Joint Conference on Computer Vision, Imaging and Computer Graphics Theory and Applications*, Prague, Czech Republic: SCITEPRESS - Science and Technology Publications, 2019, pp. 372–380. doi: 10.5220/0007364503720380.
- [8] D. Gong *et al.*, 'Memorizing Normality to Detect Anomaly: Memory-Augmented Deep Autoencoder for Unsupervised Anomaly Detection', in *2019 IEEE/CVF International Conference on Computer Vision (ICCV)*, Seoul, Korea (South): IEEE, Oct. 2019, pp. 1705–1714. doi: 10.1109/ICCV.2019.00179.
- [9] H. Park, J. Noh, and B. Ham, 'Learning Memory-Guided Normality for Anomaly Detection', in *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Seattle, WA, USA: IEEE, Jun. 2020, pp. 14360–14369. doi: 10.1109/CVPR42600.2020.01438.
- [10] L. Deecke, R. Vandermeulen, L. Ruff, S. Mandt, and M. Kloft, 'Image Anomaly Detection with Generative Adversarial Networks', in *Machine Learning and Knowledge Discovery in Databases*, vol. 11051, M. Berlingerio, F. Bonchi, T. Gärtner, N. Hurley, and G. Ifrim, Eds., in Lecture Notes in Computer Science, vol. 11051, Cham: Springer International Publishing, 2019, pp. 3–17. doi: 10.1007/978-3-030-10925-7_1.
- [11] B. Zong *et al.*, 'Deep autoencoding gaussian mixture model for unsupervised anomaly detection', in *International conference on learning representations*, 2018. Accessed: Feb. 17, 2025. [Online]. Available: <https://openreview.net/forum?id=BJJLHbb0->
- [12] J. Andrews, T. Tanay, E. J. Morton, and L. D. Griffin, 'Transfer representation-learning for anomaly detection', In: *Proceedings of the 33rd International Conference on Machine Learning*. JMLR: New York, NY, USA. (2016). Accessed: Feb. 17, 2025. [Online]. Available: <http://proceedings.mlr.press/v48/>
- [13] S. M. Erfani, S. Rajasegarar, S. Karunasekera, and C. Leckie, 'High-dimensional and large-scale anomaly detection using a linear one-class SVM with deep learning', *Pattern Recognit.*, vol. 58, pp. 121–134, Oct. 2016, doi: 10.1016/j.patcog.2016.03.028.
- [14] B. Schölkopf, J. C. Platt, J. Shawe-Taylor, A. J. Smola, and R. C. Williamson, 'Estimating the Support of a High-Dimensional Distribution', *Neural Comput.*, vol. 13, no. 7, pp. 1443–1471, Jul. 2001, doi: 10.1162/089976601750264965.
- [15] I. Golan and R. El-Yaniv, 'Deep Anomaly Detection Using Geometric Transformations', in *Advances in Neural Information Processing Systems*, Curran Associates, Inc., 2018. Accessed: Feb. 17, 2025. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2018/hash/5e62d03aec0d17facfc5355dd90d441c-Abstract.html
- [16] P. Napoletano, F. Piccoli, and R. Schettini, 'Anomaly Detection in Nanofibrous Materials by CNN-Based Self-Similarity', *Sensors*, vol. 18, no. 1, p. 209, Jan. 2018, doi: 10.3390/s18010209.
- [17] K. He, X. Zhang, S. Ren, and J. Sun, 'Deep residual learning for image recognition', in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 770–778. Accessed: Feb. 16, 2025. [Online]. Available: http://openaccess.thecvf.com/content_cvpr_2016/html/He_Deep_Residual_Learning_CVPR_2016_paper.html
- [18] M. Sabokrou, M. Fayyaz, M. Fathy, Zahra. Moayed, and R. Klette, 'Deep-anomaly: Fully convolutional neural network for fast anomaly detection in crowded scenes', *Comput. Vis. Image Underst.*, vol. 172, pp. 88–

97, Jul. 2018, doi: 10.1016/j.cviu.2018.02.006.

[19] S. Venkataramanan, K.-C. Peng, R. V. Singh, and A. Mahalanobis, ‘Attention Guided Anomaly Localization in Images’, in *Computer Vision – ECCV 2020*, vol. 12362, A. Vedaldi, H. Bischof, T. Brox, and J.-M. Frahm, Eds., in Lecture Notes in Computer Science, vol. 12362. , Cham: Springer International Publishing, 2020, pp. 485–503. doi: 10.1007/978-3-030-58520-4_29.

[20] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, ‘Grad-CAM: Visual Explanations From Deep Networks via Gradient-Based Localization’, presented at the Proceedings of the IEEE International Conference on Computer Vision, 2017, pp. 618–626. Accessed: Feb. 17, 2025. [Online]. Available: https://openaccess.thecvf.com/content_iccv_2017/html/Selvaraju_Grad-CAM_Visual_Explanations_ICCV_2017_paper.html

[21] G. Wang, S. Han, E. Ding, and D. Huang, ‘Student-Teacher Feature Pyramid Matching for Anomaly Detection’, Oct. 28, 2021, *arXiv*: arXiv:2103.04257. doi: 10.48550/arXiv.2103.04257.

[22] K. Batzner, L. Heckler, and R. König, ‘EfficientAD: Accurate Visual Anomaly Detection at Millisecond-Level Latencies’, in *2024 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, Jan. 2024, pp. 127–137. doi: 10.1109/WACV57701.2024.00020.

[23] A. Krizhevsky, I. Sutskever, and G. E. Hinton, ‘Imagenet classification with deep convolutional neural networks’, *Adv. Neural Inf. Process. Syst.*, vol. 25, 2012, Accessed: Feb. 16, 2025. [Online]. Available: <https://proceedings.neurips.cc/paper/2012/hash/c399862d3b9d6b76c8436e924a68c45b-Abstract.html>

